

Trích xuất dữ liệu từ tài liệu

Các phương pháp từ truyền thống đến hiện đại

Chủ đề: Document Parsing

Nhóm trình bày:

22120252 - Giang Đức Nhật

22120427 - Nguyễn Mạnh Văn

22120450 - Bùi Đình Gia Vỹ

1. Bài toán thực tế

Hãy tưởng tượng chúng ta xây dựng ứng dụng theo dõi chi tiêu cho một công ty.
Nhân viên tải lên hàng trăm hóa đơn mỗi ngày.

Mục tiêu: Tự động trích xuất **Ngày tháng**, **Tổng tiền**, và **Danh sách mặt hàng**.

Chúng ta thường gặp 2 loại file chính:

1. **Digital-Native PDFs:** Xuất trực tiếp từ Word/Excel. Thẳng hàng, sạch đẹp.
2. **Scanned/Image PDFs:** Ảnh chụp bằng điện thoại hoặc máy scan cũ. Mờ, nghiêng, nhiễu.

Vậy với mỗi loại file này chúng ta có những cách nào để giải quyết?

DEMO TIME (PHẦN 1)

Kịch bản A: Digital Invoice

Mục tiêu: Parse một file digital invoice

Công cụ: pdfplumber

Dự đoán: Sẽ xử lý mượt mà, lấy được bảng đẹp.

(Chuyển sang màn hình Streamlit - Mode Traditional)

2. Tại sao nó làm tốt? (Sức mạnh của pdfplumber)

Chúng ta vừa thấy pdfplumber xử lý file Digital cực nhanh và chính xác. Đây là lý do nó là "Vua" của Digital PDFs:

Ưu điểm vượt trội

1. **Table Extraction:** Khả năng xử lý bảng rất tốt (xử lý merged cells, lines).
2. **Độ chính xác 100%:** Đọc trực tiếp mã nguồn PDF, không bao giờ "nhìn nhầm" số.
3. **Tốc độ:** Xử lý ngay lập tức (Real-time).

DEMO TIME (PHẦN 2)

Kịch bản B: Scanned Invoice

Mục tiêu: Thử thách pdfplumber với file ảnh chụp (Scan). Dự đoán: ???

(Chuyển sang màn hình Streamlit - Văn Mode Traditional)

3. Tại sao nó thất bại? (Nguyên lý)

Công cụ chúng ta vừa dùng (`pdfplumber`) hoạt động dựa trên **Tọa độ (Coordinate-based)**.

Cơ chế hoạt động:

Nó KHÔNG "nhìn" thấy tài liệu như mắt người. Nó đọc **PDF Object Tree**.

- Nó tìm các lệnh như: vẽ chữ "Total" tại x=100, y=500 .

Hạn chế chết người:

- Với file Scan (Ảnh), **KHÔNG HỀ CÓ** lệnh vẽ chữ nào.
- Đối với `pdfplumber`, file scan chỉ là một trang giấy trắng chứa một bức ảnh to.
- Ngay cả với file Digital, nếu bố cục bị lệch một chút, code tọa độ cứng sẽ sai ngay.

Cơ chế bên dưới: PDF Object Tree

Để hiểu tại sao `pdfplumber` thất bại, ta phải nhìn vào **cấu trúc dữ liệu** của PDF.

PDF không phải là dạng plain text, nó là một cây đối tượng (Object Tree):

File Digital (Gốc)

Cấu trúc cây có TextObject và PathObject:

- /Page
 - /Resources
 - /Contents
 - **TextObject** (Chứa tọa độ & chữ)
 - **PathObject** (Đường kẻ bảng)

`pdfplumber` duyệt cây này để lấy dữ liệu.

File Scan (Ảnh)

Cấu trúc cây không có các TextObject:

- /Page
 - /Resources
 - /Contents
 - **XObject (Image)**
 - *(Không có TextObject nào!)*

`pdfplumber` tìm `TextObject` → Không thấy → **Rỗng**.

4. Giải pháp: Computer Vision (AI)

Khi cấu trúc cây (Object Tree) không chứa dữ liệu văn bản, ta cần một mô hình bỏ qua cấu trúc cây và "**nhìn**" vào điểm ảnh (Pixels) như con người.

Pipeline hiện đại (Ví dụ: LayoutLM, Dolphin, Azure DI):

1. **Vision Encoder:** Chuyển ảnh trang giấy thành các điểm ảnh (pixels).
2. **OCR:** Phát hiện hình dáng các con chữ (kể cả khi bị nghiêng hay mờ).
3. **Layout Analysis:** Hiểu được "Khối này là Bảng" và "Khối kia là Tiêu đề".

Nó không quan tâm code bên dưới là gì. Nó chỉ quan tâm tài liệu **trông** như thế nào.

DEMO TIME (PHẦN 2)

Cách tiếp cận "AI / Vision"

Kịch bản: Chúng ta sẽ thử đọc LẠI file **Hóa đơn Scan** (mà lúc nãy bị lỗi) bằng công nghệ Computer Vision.

(Chuyển sang màn hình Streamlit để xem AI vẽ khung hình)

Kết quả Demo (Recap)

Nếu demo chạy đúng, các bạn sẽ thấy sự khác biệt rõ rệt của 2 phương pháp này:

5	6	7	8	9	10
HOANGKIM JSC					
Công tiền hàng :					
Thuế suất GTGT :%	Tiền thuế GTGT:				
Tổng số tiền thanh toán :					
Số tiền viết bằng chữ :					
Người mua hàng			Người bán hàng		
<p>Mẫu: Ký bởi: CÔNG TY CỔ PHẦN VẬT TƯ THIẾT BỊ HOÀNG KIM Ký ngày:</p>					
Visualizing Structure: NO CELLS FOUND					
Visual Check: pdfplumber không tìm thấy cấu trúc bảng/ô nào.					
✖ EXTRACTION FAILED (0.0655s)					
Conclusion: This is a SCANNED DOCUMENT (Image).					
Why it failed?					

HÓA ĐƠN					
GIÁ TRỊ GIA TĂNG					
Ngày tháng năm					
Mẫu số : 01GKT0/001 Ký hiệu : HK/18E Số : 000000					
HOANGKIM JSC					
CÔNG TY CỔ PHẦN VẬT TƯ THIẾT BỊ HOÀNG KIM					
Mã số thuế : 0108397618					
Địa chỉ : Số nhà 18, ngõ 114, đường Thanh Bình, Phường Mộ Lao, Quận Hà Đông, Thành phố Hà Nội, Việt Nam					
Số tài khoản : 19133030911017 - Ngân hàng Techcombank - CN Hà Tây					
Tên người mua hàng					
Tên đơn vị					
Mã số thuế					
Địa chỉ					
Hình thức thanh toán					
Số tài khoản					
STT	Tên hàng hóa, dịch vụ	Đơn vị tính	Số lượng	Đơn giá	Thành tiền
1	2	3	4	5	6=4×5
1	2	3	4	5	6
2	3	4	5	6	7
3	4	5	6	7	8
4	5	6	7	8	9
5	6	7	8	9	10
6	7	8	9	10	11
7	8	9	10	11	12
8	9	10	11	12	13
9	10	11	12	13	14
10	11	12	13	14	15
11	12	13	14	15	16
12	13	14	15	16	17
13	14	15	16	17	18
14	15	16	17	18	19
15	16	17	18	19	20
16	17	18	19	20	21
17	18	19	20	21	22
18	19	20	21	22	23
19	20	21	22	23	24
20	21	22	23	24	25
21	22	23	24	25	26
22	23	24	25	26	27
23	24	25	26	27	28
24	25	26	27	28	29
25	26	27	28	29	30
26	27	28	29	30	31
27	28	29	30	31	32
28	29	30	31	32	33
29	30	31	32	33	34
30	31	32	33	34	35
31	32	33	34	35	36
32	33	34	35	36	37
33	34	35	36	37	38
34	35	36	37	38	39
35	36	37	38	39	40
36	37	38	39	40	41
37	38	39	40	41	42
38	39	40	41	42	43
39	40	41	42	43	44
40	41	42	43	44	45
41	42	43	44	45	46
42	43	44	45	46	47
43	44	45	46	47	48
44	45	46	47	48	49
45	46	47	48	49	50
46	47	48	49	50	51
47	48	49	50	51	52
48	49	50	51	52	53
49	50	51	52	53	54
50	51	52	53	54	55
51	52	53	54	55	56
52	53	54	55	56	57
53	54	55	56	57	58
54	55	56	57	58	59
55	56	57	58	59	60
56	57	58	59	60	61
57	58	59	60	61	62
58	59	60	61	62	63
59	60	61	62	63	64
60	61	62	63	64	65
61	62	63	64	65	66
62	63	64	65	66	67
63	64	65	66	67	68
64	65	66	67	68	69
65	66	67	68	69	70
66	67	68	69	70	71
67	68	69	70	71	72
68	69	70	71	72	73
69	70	71	72	73	74
70	71	72	73	74	75
71	72	73	74	75	76
72	73	74	75	76	77
73	74	75	76	77	78
74	75	76	77	78	79
75	76	77	78	79	80
76	77	78	79	80	81
77	78	79	80	81	82
78	79	80	81	82	83
79	80	81	82	83	84
80	81	82	83	84	85
81	82	83	84	85	86
82	83	84	85	86	87
83	84	85	86	87	88
84	85	86	87	88	89
85	86	87	88	89	90
86	87	88	89	90	91
87	88	89	90	91	92
88	89	90	91	92	93
89	90	91	92	93	94
90	91	92	93	94	95
91	92	93	94	95	96
92	93	94	95	96	97
93	94	95	96	97	98
94	95	96	97	98	99
95	96	97	98	99	100
96	97	98	99	100	101
97	98	99	100	101	102
98	99	100	101	102	103
99	100	101	102	103	104
100	101	102	103	104	105
101	102	103	104	105	106
102	103	104	105	106	107
103	104	105	106	107	108
104	105	106	107	108	109
105	106	107	108	109	110
106	107	108	109	110	111
107	108	109	110	111	112
108	109	110	111	112	113
109	110	111	112	113	114
110	111	112	113	114	115
111	112	113	114	115	116
112	113	114	115	116	117
113	114	115	116	117	118
114	115	116	117	118	119
115	116	117	118	119	120
116	117	118	119	120	121
117	118	119	120	121	122
118	119	120	121	122	123
119	120	121	122	123	124
120	121	122	123	124	125
121	122	123	124	125	126
122	123	124	125	126	127
123	124	125	126	127	128
124	125	126	127	128	129
125	126	127	128	129	130
126	127	128	129	130	131
127	128	129	130	131	132
128	129	130	131	132	133
129	130	131	132	133	134
130	131	132	133	134	135
131	132	133	134	135	136
132	133	134	135	136	137
133	134	135	136	137	138
134	135	136	137	138	139
135	136	137	138	139	140
136	137	138	139	140	141
137	138	139	140	141	142
138	139	140	141	142	143
139	140	141	142	143	144
140	141	142	143	144	145
141	142	143	144	145	146
142	143	144	145	146	147
143	144	145	146	147	148
144	145	146	147	148	149
145	146	147	148	149	150
146	147	148	149	150	151
147	148	149	150	151	152
148	149	150	151	152	153
149	150	151	152	153	154
150	151	152	153	154	155
151	152	153	154	155	156
152	153	154	155	156	157
153	154	155	156	157	158
154	155	156	157	158	159
155	156	157	158	159	160
156	157	158	159	160	161
157	158	159	160	161	162
158	159	160	161	162	163
159	160	161	162	163	164
160	161	162	163	164	165
161	162	163	164	165	166
162	163	164	165	166	167
163	164	165	166	167	168
164	165	166	167	168	169
165	166	167	168	169	170
166	167	168	169	170	171
167	168	169	170	171	172
168	169	170	171	172	173
169	170	171	172	173	174
170	171	172	173	174	175
171	172	173	174	175	176
172	173	174	175	176	177
173	174	175	176	177	178
174	175	176	177	178	179
175	176	177	178	179	180
176	177	178	179	180	181
177	178	179	180	181	182
178	179	180	181	182	183
179	180	181	182	183	184
180	181	182	183	184	185
181	182	183	184	185	186
182	183	184	185	186	187
183	184	185	186	187	188
184	185	186	187	188	189
185	186	187	188	189	190
186	187	188	189	190	191
187	188	189	190	191	192
188	189	190	191	192	193
189	190	191	192	193	194
190	191	192	193	194	195
191	192	193	194	195	196
192	193	194	195	196	197
193	194	195	196	197	198
194	195	196	197	198	199
195	196	197	198	199	200
196	197	198	199	200	201
197	198	199	200	201	202
198	199	200	201	202	203
199	200	201	202	203	204
200	201	202	203	204	205
201	202	203	204	205	206
202	203	204	205	206	207
203	204	205	206	207	208
204	205	206	207	208	209
205	206	207	208	209	210
206	207	208	209	210	211

Cơ chế bên dưới: AI nhìn thấy gì?

Thay vì tìm tọa độ (x, y) trong metadata, AI xử lý **Mảng các điểm ảnh (Pixel Matrix)**.

Quy trình xử lý mà Demo vừa chạy:

1. **Preprocessing:** Chuyển PDF thành Ảnh (Image) → Khử nhiễu.
2. **Text Detection:** Khoanh vùng "Ở đâu có chữ?" (Chính là các **ô màu xanh** trong demo).
3. **Text Recognition:** Cắt ô xanh đó ra và hỏi "Đây là chữ gì?".
4. **Layout Analysis:** Ghép các chữ lại thành dòng và bảng.

Sức mạnh: AI "đoán" chữ dựa trên hình dáng → Đọc được file scan, chữ viết tay.

5. So sánh & Chiến lược

Khi nào nên dùng cái nào?

Tính năng	Truyền thống (pdfplumber)	AI Hiện đại (OCR/Vision)
Phương pháp	Đọc Metadata của PDF	Đọc Pixels
Xử lý Bảng (Table)	Xuất sắc (Giữ đúng cấu trúc)	Khá (Cần xử lý hậu kỳ nhiều)
Tốc độ	Siêu nhanh (ms)	Chậm hơn (giây)
Độ tin cậy	~100%	~98% (Có thể "hallucinate"/nhìn nhầm)
Chi phí	Miễn phí / Tốn ít CPU	Cao (Cần GPU / API)
File Scan	Bó tay	Xuất sắc
Độ chính xác	100% (nếu là file gốc)	~95-99% (Xác suất)

Kết luận: Dùng phương pháp **Truyền thống** cho file digital số lượng lớn. Dùng **AI** làm phương án dự phòng (fallback) cho file xấu/scan.

6. Beyond the Basics: Enterprise Tools

| Trong thực tế Production, chúng ta thay thế script thủ công bằng các công cụ chuyên dụng.

Microsoft Dolphin / LayoutLM

"The Brain" — Bộ não

- **Loại:** Multimodal AI
- **Khả năng:** Không chỉ OCR (đọc chữ) mà còn hiểu *ngữ nghĩa & bố cục*
- **Ví dụ:** Tự biết cụm chữ in đậm ở góc trên là "Tên Công Ty" chứ không chỉ là text rời rạc.

Unstructured.io

"The Manager" — Bộ quản lý luồng dữ liệu

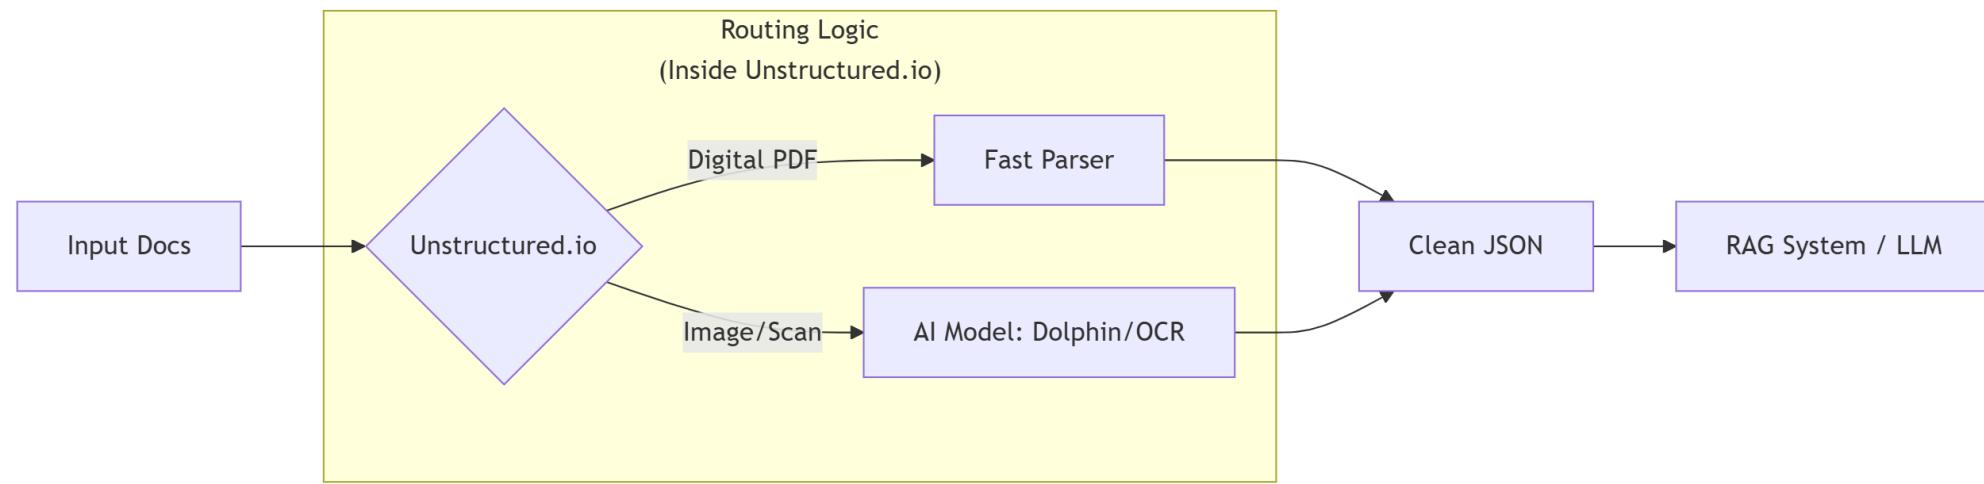
- **Loại:** ETL / Pre-processing Engine
- **Khả năng:** Tự động **routing thông minh**
 - File đẹp (Digital) → Fast Parser (chi phí thấp)
 - Scan mờ → Gọi AI Model (chi phí cao)

Kết luận:

Dolphin giúp xử lý document — Unstructured giúp tự động hóa việc chọn công cụ.

7. The Ultimate Goal: Automated Pipeline

Kết hợp tất cả lại, đây là kiến trúc chuẩn cho một hệ thống **RAG** hoặc **Data Entry** tự động:



Thông điệp: "Unstructured.io dùng để quản lý luồng xử lý file, còn pdfplumber hay Dolphin là các "engine" xử lý ở mỗi luồng."

Cảm ơn mọi người!

Công cụ sử dụng:

- **Frontend:** Streamlit
- **Thư viện:** pdfplumber
- **Concept:** OCR & Vision Transformers